

RAG → GraphRAG → LightRAG: как мы трижды переписывали медицинский AI икратно снизили издержки

Андрей Носов, AI-архитектор, Raft  raft



HighLoad++
2025

Содержание

1. Введение

За пределами «галлюцинаций» — синтез знаний как ключевой вызов MedTech RAG

Содержание

1. Введение

За пределами «галлюцинаций» — синтез знаний как ключевой вызов MedTech RAG

2. Часть 1: семантико-иерархический чанкинг

«Блестящее» решение и его 9 скрытых провалов

Содержание

1. Введение

За пределами «галлюцинаций» — синтез знаний как ключевой вызов MedTech RAG

2. Часть 1: семантико-иерархический чанкинг

«Блестящее» решение и его 9 скрытых провалов

3. Часть 2: GraphRAG-архитектуры

8 архитектур — опыты итеративного улучшения

Содержание

1. Введение

За пределами «галлюцинаций» — синтез знаний как ключевой вызов MedTech RAG

2. Часть 1: семантико-иерархический чанкинг

«Блестящее» решение и его 9 скрытых провалов

3. Часть 2: GraphRAG-архитектуры

8 архитектур — опыты итеративного улучшения

4. Часть 3: LightRAG

Гибридная архитектура как система управляемых компромиссов

Содержание

1. Введение

За пределами «галлюцинаций» — синтез знаний как ключевой вызов MedTech RAG

2. Часть 1: семантико-иерархический чанкинг

«Блестящее» решение и его 9 скрытых провалов

3. Часть 2: GraphRAG-архитектуры

8 архитектур — опыты итеративного улучшения

4. Часть 3: LightRAG

Гибридная архитектура как система управляемых компромиссов

5. Выводы

- Ключевые метрики текущего решения
- Ограничения и практические рекомендации

Вводные



HighLoad++
2025

Чего хочет MedTech?

Контекст проекта

Система	• AI-система клинической поддержки на корпусе > 10k документов
Источники	• Гайдлайны, клинические рекомендации
Нагрузка	• > 500 сложных запросов/день
Точность	• 99% (clinical safety)
Комплаенс	• 100% отслеживаемость источников (ФЗ № 152 / ФЗ № 323)

Ключевая боль

Не "галлюцинации", а отсутствие синтеза знаний из фрагментированного контекста

Чего хочет MedTech?



Клинический кейс:

запрос о назначении цисплатина пациенту с диабетической нефропатией

Извлеченные факты:

1. Эффективность цисплатина при раке легких
2. Общие риски нефротоксичности при диабете

Не синтезировано:

1. Синергический риск
2. Необходимость коррекции дозы

Чего хочет MedTech?

Последствия ошибки синтеза

- Клиническая **безопасность**: угроза здоровью пациента
- Юридические риски: несоответствие (**ФЗ-152, ФЗ-323**)
- Финансовые потери: аудит инцидента ≈ **₽ 500 000**
- Репутационные риски: **снижение доверия** врачей



Источники:

- Журнал «Врач и информационные технологии», 2024
- Клинические рекомендации Минздрава РФ по системам поддержки принятия врачебных решений, 2025


Часть 1

— RAG —



HighLoad++
2025

RAG: как все начиналось




1

Парсинг структуры документов

Использование `unstructured.io` :

- Заголовки, секции, подразделы
- Таблицы данных и их метаданные
- Списки и нумерованные элементы

RAG: как все начиналось



1

Парсинг структуры документов

Использование **unstructured.io** :

- Заголовки, секции, подразделы
- Таблицы данных и их метаданные
- Списки и нумерованные элементы




2

Семантическое чанкирование

Применение **Semantic Chunker** (Грег Камерат, 2024):

- Динамический порог косинусного расстояния между эмбедингами предложений
- Определение смысловых границ на основе семантической близости

RAG: как все начиналось



1

Парсинг структуры документов

Использование **unstructured.io** :

- Заголовки, секции, подразделы
- Таблицы данных и их метаданные
- Списки и нумерованные элементы



2

Семантическое чанкирование

Применение **Semantic Chunker** (Грег Камерат, 2024):

- Динамический порог косинусного расстояния между эмбедингами предложений
- Определение смысловых границ на основе семантической близости




3

Векторизация

Хранение в **Qdrant** с гибридным поиском:

- **embeddinggemma** для высокой точности эмбедингов
- комбинация **BM25** + векторный поиск

Первые результаты



Первые результаты



75%
Recall



Базовые запросы
✓ ~800 ms на запрос

Преимущества

- ✓ Хорошая производительность на **простых** запросах
- ✓ Высокая точность при работе со **структурированными** документами
- ✓ Рост количества **релевантных** фрагментов в контексте
- ✓ Возможность **параллельной** обработки документов
- ✓ Улучшение извлечения **конкретных** фактов

Первые результаты



75%
Recall



Базовые запросы



~800 ms на запрос

Преимущества

- ✓ Хорошая производительность на **простых** запросах
- ✓ Высокая точность при работе со **структурированными** документами
- ✓ Рост количества **релевантных** фрагментов в контексте
- ✓ Возможность **параллельной** обработки документов
- ✓ Улучшение извлечения **конкретных** фактов

Недостатки

- ✗ **Потеря** глобального контекста
- ✗ **Разрыв** неявных связей
- ✗ **Проблемы** с «сиротскими таблицами»
- ✗ Низкая **Faithfulness** (60%)

Первые результаты

Врач: «Какие риски несет химиотерапия на основе цисплатина для пациента с НМРЛ и сопутствующим сахарным диабетом?»

Ответ RAG: «Цисплатин вызывает нефротоксичность. При диабете бывает нефропатия».

Проблемы:

- Два несвязанных факта
- Отсутствие анализа взаимодействия
- Нет оценки кумулятивного риска
- Врач не получает полной картины

Часть 2


от RAG к GraphRAG



HighLoad++
2025

От RAG к GraphRAG: наши ожидания


Семанτικο-иерархический чанкинг
Recall: 75%
Faithfulness: 60%




Исследование на корпусе из >10k медицинских документов (внутренние данные проекта)
Сравнительный анализ архитектур, Q2 2025

От RAG к GraphRAG: наши ожидания

Семанτικο-
иерархический
чанкинг
Recall: 75%
Faithfulness: 60%



GraphRAG
Явные связи
Структурированные
знания




Исследование на корпусе из >10k медицинских документов (внутренние данные проекта)
Сравнительный анализ архитектур, Q2 2025

В погоне за качеством

NER + Relation Extraction,
базовая структура

BASE
GraphRAG



В погоне за качеством

NER + Relation Extraction,
базовая структура

BASE
GraphRAG

Recall

Faithfulness

Vector RAG

Стандартный векторный поиск с графом



В погоне за качеством

Recall

Faithfulness

Community-Enhanced RAG

Алгоритм Leiden для группировки контекста

NER + Relation Extraction,
базовая структура

BASE
GraphRAG

Vector RAG

Стандартный векторный поиск с графом



В погоне за качеством

Recall

Faithfulness

Community-Enhanced RAG

Алгоритм Leiden для группировки контекста

NER + Relation Extraction,
базовая структура

BASE
GraphRAG

Pathfinding RAG

Поиск кратчайшего пути между сущностями

Vector RAG

Стандартный векторный поиск с графом



В погоне за качеством

Recall

Faithfulness

Hierarchical Summarization RAG
Рекурсивное саммари сообществ в графе

Pathfinding RAG
Поиск кратчайшего пути между сущностями

Community-Enhanced RAG
Алгоритм Leiden для группировки контекста

Vector RAG
Стандартный векторный поиск с графом

NER + Relation Extraction,
базовая структура

BASE
GraphRAG



В погоне за качеством

Recall

Faithfulness

Hierarchical Summarization RAG
Рекурсивное саммари сообществ в графе

Graph-Native Chunking
Извлечение эго-сетей как контекста


Pathfinding RAG
Поиск кратчайшего пути между сущностями

Community-Enhanced RAG
Алгоритм Leiden для группировки контекста

NER + Relation Extraction,
базовая структура

Vector RAG
Стандартный векторный поиск с графом

BASE
GraphRAG



В погоне за качеством

Hybrid Search RAG

Параллельный поиск в Weaviate и Neo4j
с Reciprocal Rank Fusion

Recall

Faithfulness

Hierarchical Summarization RAG

Рекурсивное саммари сообществ в графе

Graph-Native Chunking

Извлечение эго-сетей как контекста

Pathfinding RAG

Поиск кратчайшего пути между сущностями

Community-Enhanced RAG


Алгоритм Leiden для группировки контекста

NER + Relation Extraction,
базовая структура


Vector RAG

Стандартный векторный поиск с графом

BASE
GraphRAG



В погоне за качеством



Результат на Query-Focused Subgraph RAG (QFSR)



В теории QFSR — элегантная идея, где

- LLM «понимает» контекст запроса
- LLM генерирует Cypher-запрос
- Извлекается оптимальный подграф для каждого запроса

Источники:

1. Внутренние исследования, 2024-2025

2. "Benchmarking LLM-Driven Query Generation", IEEE Database, 2025

Результат на Query-Focused Subgraph RAG (QFSR)

Врач: «Какие риски несет химиотерапия на основе цисплатина для пациента с НМРЛ и сопутствующим сахарным диабетом?»

Результат на Query-Focused Subgraph RAG (QFSR)

Врач: «Какие риски несет химиотерапия на основе цисплатина для пациента с НМРЛ и сопутствующим сахарным диабетом?»

Ответ QFSR

«Следует учитывать совместный риск. Цисплатин обладает нефротоксичностью, а диабет приводит к нефропатии, что создает кумулятивную нагрузку на почки. Рекомендуется мониторинг функции почек и возможная коррекция дозы».

Результат на Query-Focused Subgraph RAG (QFSR)

Врач: «Какие риски несет химиотерапия на основе цисплатина для пациента с НМРЛ и сопутствующим сахарным диабетом?»

Ответ QFSR

«Следует учитывать совместный риск. Цисплатин обладает нефротоксичностью, а диабет приводит к нефропатии, что создает кумулятивную нагрузку на почки. Рекомендуется мониторинг функции почек и возможная коррекция дозы».

Преимущества:

- ☐ Синтез знаний из разных источников
- ☐ Объяснение причинно-следственной связи
- ☐ Практические рекомендации
- ☐ Полное понимание рисков

А что насчёт производительности в проде?

Сравнительная таблица метрик 8 архитектур по группам на выборке 500 клинических запросов

Архитектура	Recall (%)	Latency (p95)	TCO (\$/мес)	Scalability	Faithfulness (%)
Группа 1: Базовые архитектуры					
Base GraphRAG	78	3.2 сек	\$8,000	Средняя	74
Vector RAG	75	1.8 сек	\$6,000	Высокая	60
Группа 2: Топологические архитектуры					
Community-Enhanced RAG	84	3.6 сек	\$12,000	Средняя	78
Pathfinding RAG	82	4.0 сек	\$15,000	Низкая	86
Группа 3: Изменение представления					
Hierarchical Summarization RAG	80	3.8 сек	\$14,000	Средняя	85
Graph-Native Chunking	83	2.9 сек	\$9,000	Средняя	79
Группа 4: Гибридные архитектуры					
Hybrid Search RAG	85	2.5 сек	\$11,000	Высокая	80
Query-Focused Subgraph RAG	88	4.2 сек	\$50,000	Низкая	89

Что же пошло не так?

Детальный анализ критических недостатков в условиях промышленной эксплуатации

Проблема	Описание	Влияние	Категория
Латентность	+1.5 секунды на каждый запрос только на генерацию Cypher, что критично для CDSS с требованием отклика в реальном времени	Скорость ответа системы, пользовательский опыт	Производительность
Стоимость	+1 LLM-вызов (GPT-4) на каждый запрос, что удваивало стоимость обработки и делало нерентабельным при масштабировании	ТСО системы, себестоимость запроса	Стоимость
Хрупкость Cypher	3-5% запросов падали из-за синтаксических ошибок в сгенерированном коде, что недопустимо для клинических решений	Надежность, доступность системы	Надежность
Слепота к онтологии	LLM не мог генерировать запросы для новых типов сущностей без дообучения или сложного промпт-инжиниринга	Адаптивность к новым данным	Гибкость

Что же пошло не так? (продолжение)

Детальный анализ критических недостатков в условиях промышленной эксплуатации

Чрезмерное сужение контекста	Сгенерированный подграф был настолько точным, что иногда упускал важный "соседний" контекст, необходимый для полноты ответа	Полнота ответов, обнаружение связей	Точность
Невозможность отладки	Отсутствие прозрачности в причинах генерации неэффективных Cypher-запросов, "черный ящик" в критической части системы	Обслуживаемость, устранение ошибок	Прозрачность
Нестабильность	Качество ответа стало зависеть от способности LLM к "Cypher-мышлению", которая значительно варьировалась между запросами	Стабильность качества ответов	Предсказуемость
Риски безопасности	Возможность prompt injection для генерации вредоносных Cypher-запросов (например, MATCH (n) DETACH DELETE n)	Целостность данных, защита от атак	Безопасность

Часть 3

от GraphRAG к LightRAG



HighLoad++
2025

От RAG к LightRAG

Попытка 1: семантико-иерархический чанкинг

Продвинутый чанкинг на основе семантических и структурных паттернов. Изначально многообещающее, но ошибочное решение.



От RAG к LightRAG

Попытка 2: GraphRAG-исследования

Погружение в 8 архитектур GraphRAG с использованием Neo4j и явных связей. Поиск структуры для решения проблемы синтеза.

Попытка 1: семантико-иерархический чанкинг

Продвинутый чанкинг на основе семантических и структурных паттернов. Изначально многообещающее, но ошибочное решение.



От RAG к LightRAG

Попытка 3: модифицированный LightRAG

Система управляемых компромиссов с балансом производительности, точности и стоимости. Не «серебряная пуля», но практичное решение.

Попытка 2: GraphRAG-исследования

Погружение в 8 архитектур GraphRAG с использованием Neo4j и явных связей. Поиск структуры для решения проблемы синтеза.

Попытка 1: семантико-иерархический чанкинг


Продвинутый чанкинг на основе семантических и структурных паттернов. Изначально многообещающее, но ошибочное решение.



Источники:

- Microsoft GraphRAG Research, 2024
- The Rise and Evolution of RAG, 2024

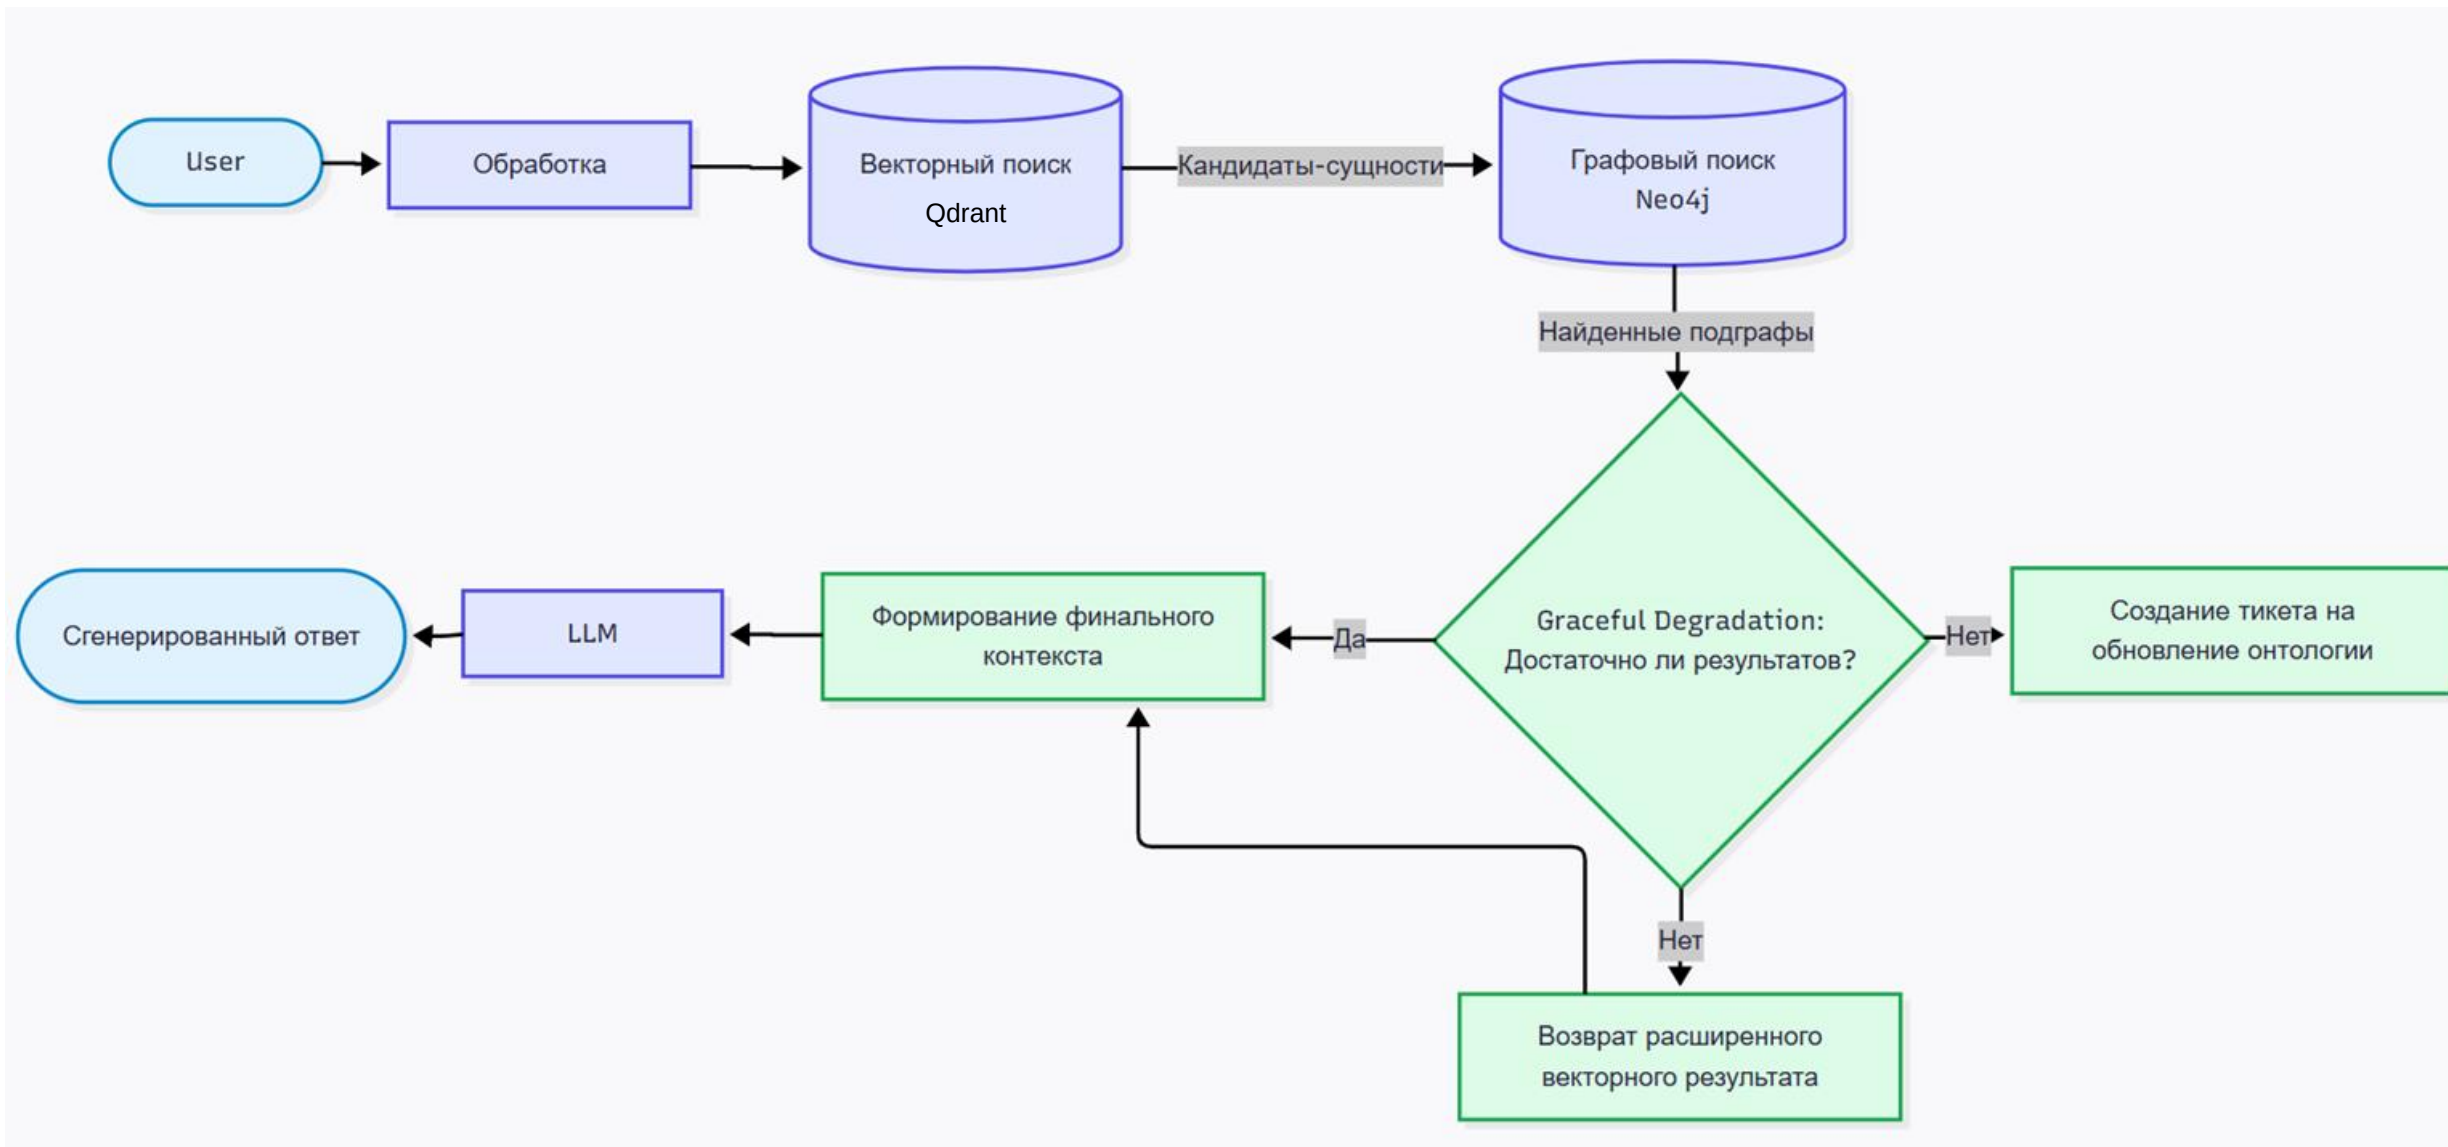
Что делать, если хочется и быстро и качественно...



GITHUB TRENDING

#1 Repository Of The Day

Retrieval пайплайн LightRAG: двухуровневый поиск



LightRAG: модификации индексации

1. Индексация


Граф - NER на MedGemma и rule-based извлечение связей.

Доработка: Внедрили фоновый "Knowledge Miner" на GPT-4o, который асинхронно ищет неочевидные связи в графе и обогащает его.


2. Двухуровневый поиск

LightRAG (векторный поиск в Qdrant → графовый поиск в Neo4j).

Доработка: Реализовали паттерн "Graceful Degradation" — если графовый поиск возвращает мало результатов (признак новой сущности), система автоматически возвращает больше "сырых" векторных результатов и создает тикет для обновления онтологии.



LightRAG: производительность компонентов



LightRAG: базовые преимущества

- ★ Баланс между **точностью** и **вычислительной эффективностью**
- ★ Использование графа знаний для **сложных связей**
- ★ Возможность **быстрого переключения** на векторный поиск
- ★ **Асинхронное обогащение знаний** вне критического пути

Источники:

1. *LightRAG: Simple and Fast Retrieval-Augmented Generation*, Guo et al., 2024

2. *GraphRAG: Unlocking LLM discovery on narrative private data*, Microsoft Research, 2025

Какие ответы мы получаем на LightRAG

Врач: "Какие риски несет химиотерапия на основе цисплатина для пациента с НМРЛ и сопутствующим сахарным диабетом?"

Ответ QFSR

"Следует учитывать совместный риск. Цисплатин обладает нефротоксичностью, а диабет приводит к нефропатии, что создает кумулятивную нагрузку на почки. Рекомендуется мониторинг функции почек и возможная коррекция дозы."

Преимущества:

- Синтез знаний из разных источников
- Объяснение причинно-следственной связи
- Практические рекомендации
- Полное понимание рисков

Метрики эффективности



TCO: < \$5k/мес (в 10 раз дешевле GraphRAG)



Latency: p95 < 2.5с (приемлемо для процессов)



Recall: 90% (+15% от базового RAG)



Faithfulness: 92% (+32% от базового RAG)



Traceability: 100% (полная отслеживаемость)

Ограничения LightRAG

Известные ограничения в промышленной эксплуатации

Ограничение	Описание	Категория	Решение
1. Отсутствие синтеза в реальном времени	LightRAG не способен динамически синтезировать знания из разных источников без предварительной индексации	Архитектура	Асинхронный Knowledge Miner
2. "Холодный старт" для новых сущностей	Новые понятия и сущности не интегрируются автоматически в существующий граф знаний	Удобство	Graceful Degradation
3. Дороговизна Knowledge Miner	Фоновое обогащение графа требует вызовов дорогих моделей (GPT-4o) и имеет существенную задержку	Стоимость	Частота обновлений
4. Ограничения векторного этапа	Если релевантный документ не попал в топ-50 на векторном этапе, связь может быть упущена	Точность	Динамический top_k
5. Зависимость от точности NER	Качество графа сильно зависит от точности дешевого NER на LLM-подобном уровне	Надежность	Периодическая переиндексация

Ограничения LightRAG (продолжение)

Известные ограничения в промышленной эксплуатации

6. Сложность обновления онтологии	Изменение схемы графа требует сложной миграции и частичной переиндексации данных	Обслуживание	Версионирование онтологии
7. "Черная магия" тюнинга	Порог (top_k) для векторного поиска сложно оптимизировать для различных типов запросов	Настройка	Профили запросов
8. Отсутствие мультимодальности	Архитектура не обрабатывает изображения, ЭКГ и другие типы мультимодальных данных нативно	Функционал	В бэклоге (CLIP)
9. Двойная инфраструктура	Требуется поддержка двух "тяжелых" компонентов (Weaviate + Neo4j) с разными моделями масштабирования	Инфраструктура	Kubernetes Operators
10. Graceful Degradation	Этот паттерн — фактическое признание архитектурного поражения в определенных случаях	Компромисс	Улучшение метрик мониторинга

Итого



🎯 Recall

75% → 90%

✓ Faithfulness

60% → 92%

🕒 Latency

4.5c → 2.5c

💰 TCO

\$50k → \$5k/мес

<https://github.com/HKUDS/LightRAG>

Заключение

кейсы переиспользования



HighLoad++
2025

Кейсы переиспользования



LegalTech

Анализ взаимосвязей в контрактах и судебных делах для выявления прецедентов и потенциальных юридических рисков.

Кейсы переиспользования



LegalTech

Анализ взаимосвязей в контрактах и судебных делах для выявления прецедентов и потенциальных юридических рисков.



FinTech (Compliance)

Построение графа транзакций и клиентов для автоматизации AML и выявления подозрительных финансовых схем.

Кейсы переиспользования



LegalTech

Анализ взаимосвязей в контрактах и судебных делах для выявления прецедентов и потенциальных юридических рисков.



FinTech (Compliance)

Построение графа транзакций и клиентов для автоматизации AML и выявления подозрительных финансовых схем.



Enterprise Search

Единый граф знаний из Confluence, Jira и Slack с контекстными связями между документами и проектами.

Кейсы переиспользования



LegalTech

Анализ взаимосвязей в контрактах и судебных делах для выявления прецедентов и потенциальных юридических рисков.



FinTech (Compliance)

Построение графа транзакций и клиентов для автоматизации AML и выявления подозрительных финансовых схем.



Enterprise Search

Единый граф знаний из Confluence, Jira и Slack с контекстными связями между документами и проектами.



Pharma R&D

Анализ исследований и клинических данных для выявления потенциальных кандидатов в лекарства и побочных эффектов.

Кейсы переиспользования



LegalTech

Анализ взаимосвязей в контрактах и судебных делах для выявления прецедентов и потенциальных юридических рисков.



FinTech (Compliance)

Построение графа транзакций и клиентов для автоматизации AML и выявления подозрительных финансовых схем.



Enterprise Search

Единый граф знаний из Confluence, Jira и Slack с контекстными связями между документами и проектами.



Pharma R&D

Анализ исследований и клинических данных для выявления потенциальных кандидатов в лекарства и побочных эффектов.



Threat Intelligence

Связывание отчетов о кибератаках для выявления паттернов и предсказания будущих векторов атак.

Спасибо за внимание



Андрей Носов



@AI_ARCHNADZOR



HighLoad++
2025

Секция «Истории GenAI-трансформации»

RAG → GraphRAG → LightRAG: как мы трижды переписывали медицинский AI и кратко снизили издержки

Андрей Носов
Raft



HighLoad++
2025

Генеральный
партнер



Оцените
доклад



Домклик
СБЕР